AGH University of Krakow

WYDZIAŁ INFORMATYKI, ELEKTRONIKI I TELEKOMUNIKACJI

Praca Magisterska

Analysis of tools for countering disinformation in the field of multimedia

Analiza narzędzi dla przeciwdziałania dezinformacji w obszarze multimediów

Autor: *Bartłomiej Pomietło*

Kierunek studiów: *Cyberbezpieczeństwo*

Opiekun pracy: *dr in. Jan Derkacz*

Kraków, 2026

Uprzedzony o odpowiedzialności karnej na podstawie art. 115 ust. 1 i 2 ustawy z dnia 4 lutego 1994 r. o prawie autorskim i prawach pokrewnych (t.j. Dz.U. z 2006 r. Nr 90, poz. 631 z późn. zm.): „Kto przywłaszcza sobie autorstwo albo wprowadza w błąd co do autorstwa całości lub części cudzego utworu albo artystycznego wykonania, podlega grzywnie, karze ograniczenia wolności albo pozbawienia wolności do lat 3. Tej samej karze podlega, kto rozpowszechnia bez podania nazwiska lub pseudonimu twórcy cudzy utwór w wersji oryginalnej albo w postaci opracowania, artystycznego wykonania albo publicznie zniekształca taki utwór, artystyczne wykonanie, fonogram, wideogram lub nadanie.”, a także uprzedzony o odpowiedzialności dyscyplinarnej na podstawie art. 211 ust. 1 ustawy z dnia 27 lipca 2005 r. Prawo o szkolnictwie wyższym (t.j. Dz. U. z 2012 r. poz. 572, z późn. zm.): „Za naruszenie przepisów obowiązujących w uczelni oraz za czyny uchybiające godności studenta student ponosi odpowiedzialność dyscyplinarną przed komisją dyscyplinarną albo przed sądem koleżeńskim samorządu studenckiego, zwanym dalej <>.”, oświadczam, że niniejszą pracę dyplomową wykonałem(-am) osobiście i samodzielnie i że nie korzystałem(-am) ze źródeł innych niż wymienione w pracy.

Abstract

The rapid advancement of generative artificial intelligence has led to a significant increase in the production of synthetic media, including AI-generated images and videos that are increasingly indistinguishable from authentic content. This phenomenon poses a serious threat to the integrity of public discourse and the reliability of visual information in the digital age. Considerable research effort is therefore being directed towards all aspects of multimedia disinformation detection, including the development of methods capable of identifying AI-generated content at scale.

This thesis focuses on the analysis of tools and techniques for countering visual disinformation, with particular emphasis on the detection of AI-generated imagery and the role of digital watermarking. Both visible and invisible watermarking schemes are examined as mechanisms for provenance verification and content authentication. A key observation motivating this work is the lack of accessible, well-integrated toolsets that would allow practitioners to reliably detect AI-generated visuals without requiring deep technical expertise.

The study evaluates existing detection approaches, analyses their strengths and limitations under real-world conditions, and proposes a fusion-based pipeline combining multiple signal-level and semantic-level indicators. The results demonstrate that a layered approach — integrating spectral analysis, optical flow, and watermark detection — achieves substantially improved detection rates while maintaining an acceptable false positive rate. The findings contribute to the broader effort of building trustworthy, practically deployable tools for multimedia authentication in the context of growing AI-driven disinformation.

Streszczenie

Gwałtowny rozwój generatywnej sztucznej inteligencji przyczynił się do znaczącego wzrostu produkcji syntetycznych mediów, w tym obrazów i filmów generowanych przez modele AI, które w coraz większym stopniu stają się nieodroznialne od treści autentycznych. Zjawisko to stanowi poważne zagrożenie dla integralności debaty publicznej oraz wiarygodności informacji wizualnej w dobie cyfrowej. Z tego powodu znaczne wysiłki badawczo-rozwojowe są kierowane na wszystkie aspekty wykrywania dezinformacji multimedialnej, w tym opracowywanie metod zdolnych do identyfikacji treści generowanych przez AI na dużą skalę.

Niniejsza praca magisterska koncentruje się na analizie narzędzi i technik przeciwdziałania dezinformacji wizualnej, ze szczególnym uwzględnieniem wykrywania obrazów generowanych przez sztuczną inteligencję oraz roli cyfrowych znaków wodnych. Badaniu poddano zarówno widzialne, jak i niewidzialne metody znakowania treści jako mechanizmy weryfikacji pochodzenia i autentyczności multimediów. Istotną obserwacją motywującą niniejsze badania jest brak latwo dostępnych, dobrze zintegrowanych zestawów narzędzi, które umożliwiałyby praktyczne wykrywanie syntetycznych treści wizualnych bez konieczności posiadania głębokiej wiedzy technicznej.

W pracy dokonano oceny istniejących podejść detekcyjnych, przeanalizowano iczh mocne i słabe strony w warunkach rzeczywistych oraz zaproponowano potok przetwarzania oparty na fuzji wielu wskaźników na poziomie sygnałowym i semantycznym. Uzyskane wyniki wskazują, że warstwowe podejście — integrujące analizę spektralną, przepływ optyczny oraz wykrywanie znaków wodnych — pozwala na znaczną poprawę skuteczności detekcji przy jednoczesnym utrzymaniu akceptowalnego wskaźnika fałszywych alarmow. Wyniki te wpisują się w szersze działania na rzecz budowy wiarygodnych, praktycznie wdrażalnych narzędzi uwierzytelniania multimediów w obliczu rozwijającej się dezinformacji opartej na AI.

Spis treści

Wykaz tabel 5

Wykaz rysunków 7

Wykaz skrótów 9

1. Wprowadzenie 11

2. Tło literaturowe 13

2.1. Generatywne modele AI w syntezie wideo 13

2.1.1. Modele GAN 13

2.1.2. Modele dyfuzyjne i latentne 13

2.1.3. Runway, Kling AI i Pika Labs 14

2.2. Detekcja deepfake – przegląd metod 14

2.2.1. Metody przestrzenne (spatial) 14

2.2.2. Analiza przepływu optycznego 14

2.2.3. Analiza widma częstotliwościowego (FFT) 15

2.2.4. Metody hybrydowe i transformerów wizyjnych 15

2.3. Znakowanie wodne treści generowanych przez AI 15

2.3.1. Niewidoczne znakowanie wodne 16

2.3.2. Podatności na usuwanie 16

2.3.3. Standardy i inicjatywy branżowe 16

2.4. Zbiory danych i benchmarki 16

2.5. Otwarte problemy i kierunki badań 17

3. Zagrożenia i techniki manipulacji multimediami 19

3.1. Taksonomia technik manipulacji 19

3.2. Techniki detekcji – przegląd ... 20
3.3. Znakowanie wodne treści generowanych przez AI ... 21
3.3.1. Znakowanie wodne widoczne ... 21
3.3.2. Znakowanie wodne niewidoczne ... 22
3.3.3. Metryki jakości znakowania wodnego ... 24
3.4. Content Provenance – C2PA ... 25
3.4.1. Czym jest C2PA? ... 25
3.4.2. Architektura i działanie ... 25
3.4.3. C2PA a detekcja AI – rola w niniejszej pracy ... 26
4. Narzędzia i metody detekcji ... 27
4.1. Zbiór danych testowych ... 27
4.2. Przegląd istniejących narzędzi internetowych ... 28
4.2.1. DetectVideo.ai ... 28
4.2.2. Undetectable.ai ... 29
4.2.3. AIVideoDetector.com ... 30
4.3. Porównanie narzędzi ... 31
4.3.1. Zestawienie komercyjnych serwisów internetowych ... 31
4.3.2. Zalety i wady proponowanego detektora ... 32
5. Implementacja i ewaluacja systemu detekcji ... 33
6. Wnioski i kierunki dalszych badań ... 35
Bibliografia ... 37

Wykaz tabel

4.1 Skład zbioru testowego według kategorii 27
4.2 Rozkład wyników DetectVideo.ai (N = 24) 28
4.3 Rozkład wyników Undetectable.ai według kategorii (N = 46) 29
4.4 Porównanie metryk klasyfikacji – N = 79 31
4.5 Porównanie komercyjnych narzędzi detekcji wideo AI 31

Wykaz rysunków

Wykaz skrótów

AI	Artificial Intelligence (Sztuczna inteligencja)
AUC	Area Under the Curve
CNN	Convolutional Neural Network
DNN	Deep Neural Network
FFT	Fast Fourier Transform
FP	False Positive
FPR	False Positive Rate
FN	False Negative
GAN	Generative Adversarial Network
LLM	Large Language Model
ML	Machine Learning
OF	Optical Flow
TP	True Positive
TPR	True Positive Rate (Recall)
UE	Unia Europejska
ViT	Vision Transformer

1. Wprowadzenie

Dynamiczny rozwój technologii generatywnej sztucznej inteligencji doprowadził do sytuacji, w której tworzenie fałszywych treści multimedialnych stało się dostępne dla szerokiego grona użytkowników bez specjalistycznej wiedzy technicznej. Narzędzia takie jak generatory wideo oparte na modelach dyfuzyjnych, systemy klonowania głosu czy generatory obrazów umożliwiają produkcję materiałów audiowizualnych o wysokim stopniu realizmu, trudnych do odróżnienia od autentycznych nagrań. Zjawisko to stanowi poważne zagrożenie dla bezpieczeństwa informacyjnego, integralności debaty publicznej oraz zaufania do mediów.

Dezinformacja multimedialna – rozumiana jako celowe rozpowszechnianie fałszywych lub zmanipulowanych treści wizualnych i dźwiękowych – nie jest zjawiskiem nowym. Jednak postęp w dziedzinie uczenia głębokiego, w szczególności modeli GAN (ang. *Generative Adversarial Network*) oraz dyfuzji latentnej, znacząco obniżył próg wejścia dla twórców fałszywych materiałów i jednocześnie podniósł ich jakość do poziomu, który utrudnia wykrycie przy użyciu tradycyjnych metod analizy. Zjawisko powszechnie znane jako *deepfake* ewoluowało od prostych podmian twarzy do kompleksowych syntez wideo, w których głos, mimika i kontekst narracyjny są generowane w całości przez modele sztucznej inteligencji.

W odpowiedzi na te zagrożenia środowisko naukowe i przemysłowe intensywnie pracuje nad narzędziami detekcji fałszywych treści multimedialnych. Metody te obejmują zarówno klasyczne techniki analizy sygnału – takie jak transformata Fouriera czy analiza przepływu optycznego – jak i nowoczesne podejścia oparte na sieciach neuronowych, w tym konwolucyjnych sieciach CNN (ang. *Convolutional Neural Network*) i transformerach wizyjnych ViT (ang. *Vision Transformer*). Różnorodność stosowanych podejść, brak jednolitych standardów ewaluacji oraz szybkie tempo ewolucji technik generatywnych sprawiają, że ocena skuteczności dostępnych narzędzi pozostaje otwartym i istotnym problemem badawczym.

Cel i zakres pracy

Celem niniejszej pracy magisterskiej jest kompleksowa analiza narzędzi stosowanych do przeciwdziałania dezinformacji w obszarze multimediów ze szczególnym uwzględnieniem detekcji treści generowanych przez sztuczną inteligencję. Praca obejmuje zarówno przegląd literatury naukowej i raportów branżowych, jak i praktyczną implementację oraz ewaluację wybranych metod detekcji na zbiorach testowych zawierających materiały wideo wygenerowane przez modele AI.

W ramach pracy zrealizowano następujące cele szczegółowe:

1. Analiza zagrożeń związanych z manipulacją treściami multimedialnymi – taksonomia technik, skala zjawiska oraz konsekwencje społeczne.

2. Przegląd i kategoryzacja dostępnych narzędzi detekcji fałszywych treści – rozwiązania komercyjne, open-source oraz metody akademickie.

3. Implementacja i ewaluacja systemu detekcji wideo generowanego przez AI, opartego na analizie artefaktów wizualnych, przepływu optycznego oraz widma częstotliwościowego.

4. Ocena skuteczności systemu przy użyciu standardowych metryk klasyfikacji binarnej: recall, FPR oraz AUC.

Struktura pracy

Praca składa się z sześciu rozdziałów. Rozdział 1 stanowi wprowadzenie do problematyki dezinformacji multimedialnej i zarysowuje cel oraz zakres pracy. Rozdział 2 zawiera przegląd literatury naukowej dotyczącej technik generowania i detekcji fałszywych treści multimedialnych. Rozdział 3 opisuje taksonomię zagrożeń – techniki manipulacji obrazem, dźwiękiem i wideo, ze szczególnym uwzględnieniem metod opartych na generatywnej AI. Rozdział 4 prezentuje przegląd narzędzi i metod detekcji, zarówno komercyjnych, jak i akademickich. Rozdział 5 opisuje implementację i ewaluację opracowanego systemu detekcji wraz z analizą uzyskanych wyników. Rozdział 6 zawiera wnioski końcowe oraz kierunki dalszych badań.

2. Tło literaturowe

Niniejszy rozdział przedstawia systematyczny przegląd literatury naukowej dotyczącej generowania i detekcji fałszywych treści multimedialnych. Omówiono kolejno: modele generatywne leżące u podstaw syntezy wideo, metody detekcji oparte na analizie obrazu i ruchu, techniki znakowania wodnego tworzące alternatywną ścieżkę weryfikacji, zbiory danych benchmarkowych oraz otwarte problemy badawcze.

2.1. Generatywne modele AI w syntezie wideo

Płynne generowanie wideo przez sztuczną inteligencję stało się praktyczną rzeczywistością dzięki ewolucji trzech głównych architektur: *Generative Adversarial Networks* (GAN), modeli dyfuzyjnych oraz modeli językowych wielomodalnych.

2.1.1. Modele GAN

Architektura GAN zaproponowana przez Goodfellowá et al. w 2014 r. [1] opiera się na grze minimax pomiędzy generatorem a dyskryminatorem. W kontekkście wideo generatywne modele GAN osiągnęły przełom z architekturą *VideoGAN* [2] oraz jej rozszerzeniami umożliwiającymi syntezę dłuższych sekwencji temporal nie koherentnych. Modele GAN były również pierwszą klasą modeli powszechnie stosowaną do tworzenia *deepfake*ów twarzy – system FaceSwap i jego pochodne opierały się na enkoderze-dekoderze trenowanym adversaryjnie [3].

2.1.2. Modele dyfuzyjne i latentne

Przejście od GAN do modeli dyfuzyjnych nastąpiło po 2022 r. Modele takie jak DALL-E 2, Stable Diffusion i Imagen demonstrowały wyższą rozmaitość generowania i lepszą stabilność

treningu [4]. Dla wideo kluczowe były modele Video Diffusion Models (Ho et al., 2022), Make-A-Video (Singer et al., 2022) i Sora (OpenAI, 2024), który wprowadził architekturę Diffusion Transformer (DiT) przetwarzającą wideo jako płatki przestrzenne i temporalne [5]. Rozdział 3 omówi szczegółowo konsekwencje tych modeli dla dezinformacji.

2.1.3. Runway, Kling AI i Pika Labs

Komercyjne modele Runway Gen-3/Gen-4/Gen-4.5, Luma Dream Machine, Kling AI i Pika Labs reprezentują nową generację systemów text-to-video dostępnych dla szerokich grup użytkowników przez interfejsy webowe [6]. Badania pokazały, że dostępność tych narzędzi obniża próg wejścia do produkcji dezinformacji multimedialnej do zera technicznego [7].

2.2. Detekcja deepfake – przegląd metod

Metody detekcji deepfake można podzielić na trzy główne klasy: (1) metody oparte na analizie pojedynczych klatek (spatial), (2) metody temporalne uwzględniające spójność ruchu w czasie, oraz (3) metody hybrydowe, łączące oba podejścia [8].

2.2.1. Metody przestrzenne (spatial)

Wczesne detektory deepfake koncentrowały się na wykrywaniu artefaktów w pojedynczych klatkach: anomaliach wokół krawędzi twarzy po blendingu, niespójnościach kolorystycznych w obszarze oczu i ust, brakach odblasków i sztucznej gładkości skory [9]. Nowoczesne podejścia używają Convolutional Neural Networks (CNN) lub Vision Transformerów (ViT) trenowanych na dużych zbiorach danych deepfake [10]. Li et al. wykazali, że specjalizowane detektory CNN osiągają AUC powyżej 0,95 na zbiorze FaceForensics++ w warunkach controlled, natomiast spadły do 0,65–0,72 na materiałach z Internetu po wielokrotnej kompresji [7].

2.2.2. Analiza przepływu optycznego

Przepływ optyczny (*optical flow*) jest kluczową cechą temporalą wykorzystywaną w detekcji wideo AI. Amerini et al. [11] zaproponowali architekturę CNN przyjmującą na wejściu mapy przepływu optycznego zamiast klatek wideo, uzyskując znaczącą poprawę wykrywalności dla

filmów deepfake z podmianą twarzy. Caldelli et al. [12] rozszerzyli te wyniki pokazując, że modele oparte na przepływie lepiej generalizują na nieznane typy manipulacji, ponieważ kodują temporalną niespójność globalną, niezależną od konkretnej techniki generowania. Nassif et al. [13] zaproponowali ulepszony estymator przepływu odporny na kompresję wideo, co jest istotne dla materiałów pobieranych z platform społecznościowych.

2.2.3. Analiza widma częstotliwościowego (FFT)

Transformata Fouriera (FFT) umożliwia analizę rozkładu częstotliwości w klatkach wideo. Badania wykazywały, że obrazy generowane przez sieci neuronowe wykazują charakterystyczne artifakty w dziedzinie częstotliwości – nieregularne piki wynikające z artefaktów upsamplingu (*checkerboard pattern*) i specyficznych filtrów splotowych [14]. Artifakty te są często niewidoczne gołym okiem, ale statystycznie odstąpują od rozkładu widmowego naturalnych nagrań kamerowych. *Szum sensora* kamery – zwany też sygnałem PRNU (*Photo-Response Non-Uniformity*) – występuje w autentycznych nagraniach jako porąwnywalny charakterystyczny wzorzec, który jest nieobecny lub zmodyfikowany w treściach generowanych AI [8].

2.2.4. Metody hybrydowe i transformerów wizyjnych

Nowsze prace proponują połączenie cech przestrzennych i temporalnych w jednym modelu. Badania z zastosowaniem Vision Transformerów (ViT) pokazały, że mechanizm uwagi (*attention*) jest zdolny do identyfikacji lokalnych niespójności w deepfakeách nawet przy dużej jakości generowania [10]. Oddzielnie, modele *CLIP-based* pozwalają wykoryśtywać reprezentacje wizualno-językowe do zero-shot detekcji nowych modeli generatywnych, na których klasyczne detektory nie były trenowane [7].

2.3. Znakowanie wodne treści generowanych przez AI

Alternatywną ścieżką weryfikacji autentyczności jest proaktywne znakowanie wodne treści przez ich twórców (modele AI). W odróżnieniu od detekcji post-hoc, która analizuje treść po opublikowaniu, znakowanie wodne opiera się na osadzeniu niewidocznego lub widocznego identyfikatora w momencie generowania.

2.3.1. Niewidoczne znakowanie wodne

Modele takie jak HiDDeN [15] i jego następcy uczą się osadzać bity informacji w piksalch obrazu w sposób niezauważalny dla człowieka, ale wykrywalny przez koder. Luo et al. [16] dokonali przeglądu metod znakowania wodnego dla treści AIGC, wykazując, że aktualne metody są podatne na ataki transformacji (zmiana rozdzielczości, kompresja JPEG, konwersja formatu wideo). Najaf-Abadi et al. [17] zaproponowali robustny schemat oparty na głębokich sieciach neuronowych odporny na większość klasycznych ataków geometrycznych.

2.3.2. Podatności na usuwanie

Zhao et al. [18] wykazali, że niewidoczne znaki wodne mogą być usunięte przy użyciu modeli generatywnych bez znaczącej degradacji jakości obrazu. To fundamentalne ograniczenie sprawia, że samo znakowanie wodne nie może być jedyną warstwą weryfikacji. Fernandez et al. [19] zaproponowali znakowanie wodne odporne na ataki geometryczne (obrót, przycinanie), ale podatne na adversaryjne usuwanie.

2.3.3. Standardy i inicjatywy branżowe

Piet et al. [20] dokonali systematyzacji (SoK) metod znakowania wodnego dla treści AIGC, wyodrębniając wymagania: skalowalność, odporność na usuwanie i falsyfikację, niską utratą jakości treści. Żaden z aktualnych systemów nie spełnia jednocześnie wszystkich tych wymagań. Inducja Content Credentials (C2PA) [21] podejmuje podejście metadanowe: każdy plik może nosić cyfrowo podpisany lancuch proweniencji informujący o historii edycji.

2.4. Zbiory danych i benchmarki

Jakość oceny metod detekcji zależy bezpośrednio od stosowanych zbiorów danych. Kluczowe benchmarki obejmują:

– **FaceForensics++** [22] — 100 filmów z Internetu, zmanipulowanych czterema metodami (Deepfakes, FaceSwap, Face2Face, NeuralTextures) z trzema poziomami kompresji. Najczęściej cytowany benchmark dla face-swap deepfake.

- **DFDC (DeepFake Detection Challenge)** [23] — zbiór Meta/Facebook zawierający 100 000+ filmów generowanych przez 8 metod. Opublikowany w 2020 r. w ramach Kaggle competition z nagrodą 1 mln USD.
- **DGM^4** [24] — nowszy zbiór obejmujący multimodalne fałszerstwa (text + obraz), odpowiadający realiom dezinformacji AIGC.
- **GenVideo** [25] — zbiór ponad 250 000 klipów z 18 modeli text-to-video (Sora, Runway, Kling, Pika, Stable Video Diffusion); dedykowany ewaluacji detektorów dla nowej generacji modeli generatywnych.

Głównym problemem benchmarkowym jest **transfer gap**: modele trenowane na FaceForensics++ lub DFDC generalizują słabo na nowe, niewidziane modele generatywne [26]. Badania konsekwentnie potwierdzają, że AUC detektora spada o 10–30 punktów procentowych przy testowaniu na nowym generatorze [8].

2.5. Otwarte problemy i kierunki badań

Literatura identyfikuje kilka kluczowych otwartych problemów:

2.5.0.0.1 Generalizacja między-modelowa. Głównym wyzwaniem jest budowa detektorów, które działają skutecznie na modeli niebędących częścią zbioru treningowego. Sun et al. [25] wykazali, że detektory trenowane na starszych modelach GAN osiągają tylko $\sim$60% AUC na filmach z Kling AI czy Runway Gen-4.

2.5.0.0.2 Odporność na kompresję i postprocessing. Większość materiałów w Internecie przechodzi wielokrotną reenkodację (YouTube, TikTok, Messenger). Badania [12, 13] pokazały, że artefakty spektralne i przepływ optyczny są wrażliwe na kompresję H.264/H.265 o wysokim współczynniku.

2.5.0.0.3 Fałszywe alarmy na treściach broadcastowych. Animowane grafiki newsowe (*lower thirds*), elementy Augmented Reality i renderowane reklamy 3D systematycznie generują fałszywe alarmy we wszystkich znanych klasach detektorów. Jest to empirycznie potwierdzone w niniejszej pracy (sekcja 4.2.3) oraz w literaturze [8].

2.5.0.0.4 Interpretowalność decyzji. Większość komercyjnych narzędzi zwraca jedynie wynik liczbowy bez wyjaśnienia, które sygnały zadecydowały o klasyfikacji. Badania z zakresu XAI (*eXplainable AI*) stosowane do deepfake należą do mniejszości w literaturze [3].

2.5.0.0.5 Wyścig zbrojeń. Każda nowa generacja modeli generatywnych wymaga przetrenowania detektorów. Badania [7] sugerują, że podejścia oparte na cechach fundamentalnych (FFT, optical flow, metadane) są bardziej trwałe niż podejścia CNN trenowane end-to-end na konkretnych modelach.

3. Zagrożenia i techniki manipulacji multimediami

Rozdział opisuje taksononomię zagrożeń związanych z fałszowaniem treści multimedialnych, techniki generowania i manipulacji oraz metody weryfikacji autentyczności oparte na znakowaniu wodnym. Sekcja 3.3 omówiona jest szczegółowo, ponieważ znakowanie wodne stanowi kluczowy kontekst dla oceny ograniczeń narzędzi detekcji omowionych w rozdziale 4.

3.1. Taksonomia technik manipulacji

Techniki generowania i manipulacji multimediami można podzielić na pięć głównych kategorii:

1. **Podmiana twarzy (face swap)** — zamiana twarzy jednej osoby na twarz innej przy zachowaniu ruchu głowy i mimiki oryginału. Historycznie realizowana przez sieci GAN (DeepFaceLab, FaceSwap); współcześnie także przez modele dyfuzyjne.

2. **Synteza twarzy (face reenactment)** — przeniesienie ekspresji i ruchu ust z nagrania źródłowego na docelowe nagranie innej osoby. Techniki: First Order Motion Model, DiffusionFace.

3. **Synteza całej sceny (text-to-video)** — generowanie pełnej sekwencji wideo z opisu tekstowego (OpenAI Sora, Runway Gen-3/4, Kling AI, Luma Dream Machine, Pika Labs). Używa architektur Diffusion Transformer (DiT) lub dyfuzji latentnej.

4. **Manipulacja audio (voice cloning)** — klonowanie głosu na podstawie próbki kilku sekund nagrania (ElevenLabs, Tortoise TTS). Często łączone z manipulacją wideo w kompletnych *deepfake*ách audio-wideo.

5. **Manipulacja dokumentami i zdjęciami** — edycja treści obrazu (inpainting) lub dokumentu (paszporty, certyfikaty) przy użyciu modeli generatywnych.

Skalę zagrożenia ilustruje fakt, że raport Europolu z 2023 r. szacuje, iż do roku 2026 ponad 90% treści w Internecie może być wygenerowane lub zmodyfikowane przez AI [**Europol2023Deepfakes**]. Wpływ dezinformacji multimedialnej dokumentują liczne badania — w szczególności w kontekstach wyborczym, bankowym i wojennym [3].

3.2. Techniki detekcji – przegląd

Techniki detekcji omawiane szczegółowo w literaturze (rozdział 2) można podzielić na trzy podejścia:

Post-hoc (passive) – Analiza pliku po jego opublikowaniu, bez wcześniejszego oznakowania. Obejmuje metody spektralne (FFT), przepływ optyczny, analizę klatek przez CNN/ViT i analizę metadanych. Opisano w sekcji 2.2.

Proaktywne (active) – Osadzenie znaku wodnego w momencie generowania lub edycji. Weryfikacja polega na odczycie znaku. Opisano szczegółowo w sekcji 3.3.

Provenienencja (C2PA) – Kryptograficznie podpisany łańcuch metadanych o historii pliku. Opisano w sekcji 3.4.

3.3. Znakowanie wodne treści generowanych przez AI

Znakowanie wodne (*digital watermarking*) polega na osadzeniu w pliku multimedialnym informacji identyfikacyjnej w taki sposób, aby była ona trudna do usunięcia lub niezauważalna dla obserwatora [16]. W kontekcie treści generowanych przez AI technologia ta pozwala na jednoznaczne oznaczenie materiału już w momencie jego tworzenia, co tworzy alternatywną ścieżkę weryfikacji — niezależną od analizy artefaktów wizualnych.

3.3.1. Znakowanie wodne widoczne

Widoczny znak wodny (*visible watermark*) jest celowo prezentowany w polu widzenia odbiorcy — typowo jako logotyp, napis lub wzorzec geometryczny nałożony na treść.

3.3.1.0.1 Zastosowania. Znaki wodne widoczne stosowane są przez platformy dystrybucji treści (Getty Images, Shutterstock, Adobe Stock) jako ochrona praw autorskich. W kontekcie AI kilka generatorów obrazu/wideo domyslnie dodaje widoczne logo do bezpłatnych wersji (Runway, Pika Labs, Kling AI).

3.3.1.0.2 Metody usuwania. Widoczne znaki wodne są podatne na usuwanie przez:

- przycinanie lub kadrowanie obszaru ze znakiem;
- inpainting oparty na modelach generatywnych (np. Stable Diffusion z maską);
- sieciowe detektory-usuwacze, trenowane na parach „z znakiem / bez znaku”.

3.3.1.0.3 Detekcja widocznych znaków. Weryfikacja polega na prostej analizie obrazu: detekcja szablonowa (template matching), segmentacja semantyczna lub klasyczna analiza histogramowa w obszarze typowego umieszczenia logotypu. Nie jest to technika odporna na usuwanie.

3.3.2. Znakowanie wodne niewidoczne

Niewidoczny znak wodny (*invisible/steganographic watermark*) zostaje osadzony w danych pliku w sposób niezauważalny golym okiem, ale możliwy do odczytu przez specjalistyczny dekoder.

3.3.2.1. Metody osadzania

3.3.2.1.1 LSB (Least Significant Bit). Najprostsza metoda: zapis informacji w najmniej znaczących bitach pikseli. Niew idoczna, ale skrajnie wrażliwa na kompresję i konwersję formatu.

3.3.2.1.2 DCT/DWT – dziedzina częstotliwości. Informacja osadzana jest w współczynnikach transformaty DCT (JPEG) lub falkowej DWT, zwykle w pasmach średnich częstotliwości. Mówi się, że metoda ta jest bardziej odporna na kompresję niż LSB, ponieważ koduje informację w strukturze postrzeganej przez algorytm kompresji jako „znaczna".

3.3.2.1.3 Sieci neuronowe – HiDDeN i następcy. Architektura **HiDDeN** [15] (*Hiding Data with Deep Networks*) trenuje jednocześnie enkoder (osadza wiadomość) i dekoder (odczytuje wiadomość), minimalizując both straty postrzeganej jako wygladu i straty binarnego odczytu wiadomości. Konkurencyjne podejście – **StegaStamp** – osadza do 100 bitów informacji odpornych na wydruk i skanowanie. Fernandez et al. [19] rozszerzyli to podejście o odporność na ataki geometryczne (obrót, przyspieszenie).

3.3.2.1.4 Watermarking spektralny dla wideo. Dla wideo dodatkowym kanałem jest osadzanie znaku w dziedzinie temporalnej: modyfikacja fazy przepływu optycznego między klatkami lub wstrzyknięcie percepcyjnie niewidocznego wzorca migotania o określonej częstotliwości [16].

3.3.2.2. Metody wykrywania znaku niewidocznego

Weryfikacja niewidocznego znaku wodnego może być realizowana następującymi podejściami:

1. **Detekcja z kluczem (blind detection)** — dekoder otrzymuje jedynie plik do weryfikacji i klucz prywatny; nie ma dostępu do oryginału. Osiągalne przez sieci neuronowe trenowane end-to-end. Jest to standard w praktycznych systemach.

2. **Detekcja referencyjna (non-blind)** — dekoder porównuje plik ze zdekodowanym oryginałem; dokładniejsza, ale wymaga przechowania oryginału.

3. **Analiza statystyczna szumu** — bez dekodera: analiza residuum po odjęciu przetworzonego obrazu od predykcji generowanej przez model kompresji. Szum residuum zawiera sygnał znaku wodnego wykrywalny progowym testem hipotez (test χ^2 lub Neymana-Pearsona).

4. **PRNU-based verification** — Porównanie wzorca szumu sensora kamery (Photo-Response Non-Uniformity) z wzorcem wydobytym z podejrzanego nagrania. Metoda stosowana do weryfikacji żródła nagrania, nie jako znak wodny wprost, ale analogiczny mechanizm [8].

3.3.2.3. Odporność a ataki

Zhao et al. [18] wykazali, że niewidoczne znaki wodne mogą być **usunięte przy użyciu modeli generatywnych** bez znaczącej degradacji jakości wizualnej. PrzegLąd SoK [20] identyfikuje pięć klas ataków:

1. **Kompresja i reenkodacja** — kompresja H.264/H.265 lub JPEG niszczy sygnały LSB i częściowo sygnały DCT.

2. **Ataki geometryczne** — przycinanie, zmiana rozdzielczości, obroty naruszają przestrzenne położenie znaku.

3. **Szumienie i filtrowanie** — Gaussian blur, median filter, dodanie szumu gaussowskiego.

4. **Ataki adwersaryjne** — optymalizacja perturbacji pikseli niszczącej znak przy minimalnej zmianie postrzeganego wyglądu.

5. **Regeneracja przez model AI** — przepuszczenie obrazu przez model dyfuzyjny (*diffusion purification*) usuwa znak zachowując semantykę obrazu.

Żaden z aktualnie dostępnych systemów nie jest odporny jednocześnie na wszystkie klasy ataków.

3.3.3. Metryki jakości znakowania wodnego

Ewaluacja systemu znakowania wodnego wymaga oceny dwóch przeciwstawnych właściwości:

Niepostrzegalność (imperceptibility) Mierzona metrykam postrzegania jakości obrazu: **PSNR** (*Peak Signal-to-Noise Ratio*),

– **SSIM** (*Structural Similarity Index*) oraz **LPIPS** (*Learned Perceptual Image Patch Similarity*). Wyższy PSNR i SSIM oznacza mniejszą ingerencję w obraz.

Odporność (robustness) Mierzona **BER** (*Bit Error Rate*) — odsetkiem błędnie odczytanych bitów wiadomości

– po ataku. Cel: BER $< 5\%$ po typowych transformacjach (kompresja, zmiana rozdzielczości).

Dodatkowo stosuje się metryki skuteczności detekcji w ujęciu binarnym:

– **True Positive Rate (TPR)** — odsetek poprawnie wykrytych znaków.

- **False Positive Rate (FPR)** — odsetek plików nieoznaczonych, które system błędnie sklasyfikował jako oznakowane.
- **AUC-ROC** — pole pod krzywdą klasyfikatora dla różnych progów detekcji.

3.4. Content Provenance – C2PA

3.4.1. Czym jest C2PA?

C2PA (*Coalition for Content Provenance and Authenticity*) to otwarta specyfikacja techniczna opracowana wspólnie prze Adobe, Microsoft, Intel, BBC, Sony i Truepic [21]. Definiuje format **Content Credentials** — cyfrowo podpisanego zestawu metadanych opisujących historię powstania i edycji pliku multimedialnego.

C2PA nie jest systemem detekcji w rozumieniu analizy artefaktów — jest natomiast mechanizmem **proweniencji kryptograficznej**: weryfikacja polega na sprawdzeniu podpisu cyfrowego (X.509), nie na ocenie treści.

3.4.2. Architektura i działanie

Każdy plik z obsługą C2PA może zawierać **Manifest** — strukturę JSON osadzoną w pliku lub powiązaną z nim przez hash. Manifest składa się z:

- **Claim** — wykaz wykonanych operacji (generowanie, edycja, kadrowanie) wraz z timestamp.
- **Assertions** — szczegółowe twierdzenia o treści: użyte narzędzie (np. `c2pa.ai.generative`), model, parametry.
- **Claim Signature** — podpis ECDSA (lub RSA) na zawartości Claim, wystawiony przez certyfikat X.509 tworca lub narzędzia.
- **Ingredients** — opcjonalne odwołania do plików wejściowych (np. oryginalne zdjęcie przed edycją) z ich hashami SHA-256.

Procedura weryfikacji po stronie odbiorcy:

1. Odczyt Manifestu z pliku lub rejestru online.
2. Sprawdzenie integralności: hash pliku musi zgadzać się z wartością w Claim.
3. Weryfikacja podpisu ECDSA względem certyfikatu X.509 wystawcy.
4. Sprawdzenie łańcucha zaufania certyfikatu (Certificate Transparency, OCSP).
5. Ocena treści Assertions — czy plik zawiera oznaczenie `c2pa.ai.generative`.

3.4.3. C2PA a detekcja AI – rola w niniejszej pracy

Analiza metadanych C2PA stanowi jeden z kanałów sygnałów w proponowanym detektorze. Jeśli plik zawiera ważny Manifest C2PA z asercją `c2pa.ai.generative`, system automatycznie klasyfikuje go jako wygenerowany przez AI z wysoką pewnością, bez konieczności dalszej analizy wizualnej.

C2PA ma jednak kluczowe ograniczenia:

- **Wdrożenie nie jest powszechne** — tylko część modeli generatywnych osadza Content Credentials (Adobe Firefly, Stable Diffusion 3 z odpowiednią konfiguracją); Runway, Sora i Kling AI nie stosują C2PA standardowo.
- **Metadane można usunąć** — prosta reenkodacja pliku (FFmpeg bez flag zachowania metadanych) usuwa Manifest. System musi traktować brak Manifestu jako wynik nierozstrzygnięty, nie jako dowód autentyczności.
- **Fałszywy Manifest** — atakujący może teorytycznie wystawiać Manifestu z samopodpisanym certyfikatem; weryfikacja łańcucha zaufania jest kluczowa.

Pomimo tych ograniczeń C2PA jest obiecującym standardem długoterminowym. Inicjatywy takie jak **Google DeepMind SynthID** (znakowanie wodne generowane w modelu) i **Meta Watermarking** zmierzają w kierunku, w którym każda treść AI będzie noslą kryptograficzne oznaczenie niezależnie od platform.

4. Narzędzia i metody detekcji

4.1. Zbiór danych testowych

Do ewaluacji narzędzi detekcji treści generowanych przez sztuczną inteligencję przygotowano zbiór 48 filmów wideo, obejmujący materiały syntetyczne wygenerowane przez różne modele generatywne, materiały zmanipulowane (deepfake), autentyczne nagrania kamerowe oraz materiały kontrolne. Tabela 4.1 prezentuje skład zbioru według kategorii.

Tabela 4.1. Skład zbioru testowego według kategorii

Kategoria	**Liczba filmów**	**Źródło / Model**
Syntetyczne – Runway Gen-3	11	Runway Gen-3
Syntetyczne – Runway Gen-4 Turbo	5	Runway Gen-4 Turbo
Syntetyczne – Runway Gen-4.5	2	Runway Gen-4.5
Syntetyczne – OpenAI Sora	5	OpenAI Sora
Syntetyczne – Luma Dream Machine	3	Luma Dream Machine
Syntetyczne – Kling AI	6	Kling AI
Syntetyczne – Pika Labs	2	Pika Labs
Syntetyczne – Grok (xAI)	3	Grok
Syntetyczne – inne modele AI	4	różne
Razem syntetyczne	*41*	
Autentyczne nagrania (klasa negatywna)	3	nagrania kamerowe
Materiały kontrolne (corner cases)	7	reklamy, recenzje aplikacji
Razem	**51**	

Różnorodność modeli generatywnych (9 różnych systemów) oraz zróżnicowanie stylów wizualnych — od realistycznych scen ulicznych po abstrakcyjne animacje — pozwala na rzetelną ocenę skuteczności narzędzi detekcji.

4.1.0.0.1 Corner cases. Siedmioro materiałów z kategorii kontrolnej po ręcznej weryfikacji okazało się nagraniami *screen capture* interfejsów lub recenzjami aplikacji — nie są to filmy wygenerowane przez AI w ścisłym sensie. Zostały one wykluczone z głównej ewaluacji metryk klasyfikacji, lecz pozostają w zbiorze jako przykłady trudnych przypadków.

4.2. Przegląd istniejących narzędzi internetowych

Na rynku dostępnych jest kilka publicznie dostępnych serwisów internetowych omawiających detekcję treści generowanych przez AI. W niniejszej sekcji omówiono trzy serwisy testowane w ramach niniejszej pracy: DetectVideo.ai (sekcja 4.2.1), Undetectable.ai (sekcja 4.2.2) oraz AIVideoDetector.com (sekcja 4.2.3).

4.2.1. DetectVideo.ai

DetectVideo.ai to serwis internetowy oferujący detekcję filmów wideo pod kątem pochodzenia z modeli generatywnych AI. Narzędzie zwraca wynik w postaci procentowego prawdopodobieństwa tego, że przesłany plik został wygenerowany lub zmanipulowany przez AI.

4.2.1.1. Wyniki na zbiorze testowym

Przeprowadzono test na podzbiorze 24 plików obejmującym materiały syntetyczne, zmanipulowane i autentyczne. Tabela 4.2 pokazuje rozkład wyników.

Tabela 4.2. Rozkład wyników DetectVideo.ai (N = 24)

Wynik AI likelihood	Liczba filmów	Typy materiałów
55% (nierozstrzygnięty)	20	syntetyczne, autentyczne, deepfake
72% (podejrzany)	4	abstrakcja, fantasy, zmanipulowany dokument
Razem	**24**	

4.2.1.2. Analiza wyników

Serwis DetectVideo.ai zwrócił wynik **55%** dla **20 z 24 plików** (83%), w tym dla autentycznych nagrań kamerowych. Wynik 55% stanowi de facto domyślną odpowiedź „nie wiem" — nie jest to faktyczna ocena zawartości wizualnej. Wyższy wynik (72%) uzyskały jedynie filmy z wyraźnymi cechami generatywnymi (abstrakcja, fantasy) oraz zmanipulowany dokument, co wskazuje na działanie oparte głównie na analizie metadanych, a nie treści wizualnej.

4.2.2. Undetectable.ai

Undetectable.ai to serwis internetowy oferujący analizę wielokanałową: kanał obrazu (*Image score*) oraz kanał ruchu (*Motion score*). Końcowy wynik podawany jest w skali 0–100. Serwis wyodrębnia cztery etykiety jakościowe: *Strong authentic* (0–20), *Mostly authentic* (21–49), *Likely AI elements* (61–79) i *Likely AI-Generated* (80–100).

4.2.2.1. Wyniki na pełnym zbiorze testowym

Przeprowadzono testy na 46 plikach (2 odrzucone przez moderację systemu). Tabela 4.3 przedstawia rozkład etykiet według kategorii materiału.

Tabela 4.3. Rozkład wyników Undetectable.ai według kategorii (N = 46)

Kategoria	AI-Generated	AI elements	Mostly authentic	Strong authentic
Syntetyczne (38 filmów)	30	3	4	1
Kontrola / corner cases (7 filmów)	1	0	1	5
Autentyczne (1 plik w teście)	0	0	0	1
Razem (46)	**31**	**3**	**5**	**7**

4.2.2.2. Analiza wyników

Średni wynik dla filmów syntetycznych wynosił **82,4** przy medianie **88**, co potwierdza skuteczność kanału Image score dla zdecydowanej większości materiałów. Kanał Motion okazał się bardziej zróżnicowany: filmy o statycznych lub spokojnych scenach (portret, płomień, sceny wodne) uzyskały niski wynik ruchu, co przekładało się na niższą klasyfikację końcową.

Zidentyfikowano cztery kategorie trudnych przypadków:

- **Fotorealistyczne sceny nocne i wodne** — wysoka jakość generowania skutecznie naśladuje teksturę i szum naturalnej kamery.

- **Klipy muzyczne i artystyczne** — hybryda prawdziwego tła z efektami AI utrudnia jednoznaczną klasyfikację.

- **Portrety i sceny statyczne** — niski Motion score przy wysokim Image score; wynik końcowy bywa niedoszacowany.

- **Screen-capture / recenzje** — serwis poprawnie klasyfikuje je jako niesyntetyczne (Strong authentic), co potwierdza ich status corner case.

4.2.3. AIVideoDetector.com

AIVideoDetector.com to kolejny publicznie dostępny serwis detekcji filmów AI. Narzędzie zostało przetestowane na zbiorze 41 autentycznych filmów w celu wyznaczenia wskaźnika fałszywych alarmów (FPR).

4.2.3.1. Wskaźnik fałszywych alarmów

Serwis błędnie zakwalifikował **7 z 41 autentycznych filmów** jako wygenerowane przez AI:

$$\text{FPR} = \frac{7}{41} \approx 17{,}1\%$$

Wszystkie 7 fałszywych alarmów dotyczyło materiałów z **animowanymi elementami graficznymi** — lower thirds, naklejki AR lub renderowane reklamy 3D — niekładami na obraz kamerowy. Uzyskały one wyniki w zakresie 50–91, co sugeruje, że modele tych detektorów interpretują gładką animację komputerową jako cechę generatywną.

4.2.3.2. Analiza wzorca błędów

Wzorzec fałszywych alarmów jest identyczny z błędami własnego detektora. Sugeruje to, że skłonność do fałszywych alarmów na materiałach broadcastowych z animowanymi naklejkami stanowi **systemowe ograniczenie całej klasy detektorów** opartych na analizie statystycznej obrazu — nie jest to wada konkretnego rozwiązania.

4.2.3.3. Porównanie metryk (N = 79)

Tabela 4.4 przedstawia porównanie głównych metryk klasyfikacji dla własnego detektora i serwisu AIVideoDetector.com.

Tabela 4.4. Porównanie metryk klasyfikacji – N = 79

Metryka	Nasz system	AIVideoDetector.com
Accuracy	78,9%	79,7%
Precision	**82,9%**	80,6%
Recall	74,4%	76,3%
F1	78,4%	78,4%
FPR	**16,2%**	17,1%

Wyniki obu systemów są praktycznie identyczne — F1 wynosi dokładnie 78,4% dla obu narzędzi. Proponowany detektor przewyższa AIVideoDetector.com pod względem Precision i FPR, natomiast AIVideoDetector.com uzyskuje nieznacznie wyższą Accuracy i Recall.

4.3. Porównanie narzędzi

4.3.1. Zestawienie komercyjnych serwisów internetowych

Tabela 4.5. Porównanie komercyjnych narzędzi detekcji wideo AI

Narzędzie	Zalety	Wady
DetectVideo.ai	Prosty interfejs; nie wymaga rejestracji	83% wyników to nierozstrzygnięte 55%; brak realnej analizy wizualnej; brak XAI
Undetectable.ai	Analiza wielokanałowa (Image + Motion); czytelna skala 0–100; skuteczny dla starszych modeli Gen-3	Błędy na fotorealistycznych i statycznych scenach; limit dzienny; odrzucanie plików przez moderację
AIVideoDetector.com	Skuteczność F1 = 78,4%; przejrzysty wynik liczbowy	FPR = 17,1% – systematyczne fałszywe alarmy dla materiałów z animowanymi naklejkami

4.3.2. Zalety i wady proponowanego detektora

Proponowane podejście opiera się na fuzji wielokanałowej: analiza spektralna (FFT), przepływ optyczny i metadane.

4.3.2.0.1 Zalety.

- **Decyzja binarna** — jednoznaczna klasyfikacja AI / nie AI bez wyników nierozstrzygniętych.
- **Wielosygnałowość** — połączenie FFT, optical flow i metadanych zwiększa odporność na manipulacje pojedynczym kanałem.
- **Interpretowalny wynik (XAI)** — wagi składowych sygnałów umożliwiają analizę przyczynową decyzji.
- **Praca lokalna** — przetwarzanie bez wysyłania danych do chmury.
- **Konkurencyjna skuteczność** — F1 = 78,4%, Precision 82,9%, FPR 16,2%.

4.3.2.0.2 Wady i ograniczenia.

- **Czułość na kompresję** — silna kompresja H.264/H.265 wytłumia sygnały spektralne.
- **Krótkie klipy** — materiały poniżej 5 sekund dostarczają niewystarczającej liczby klatek.
- **Systemowy blind spot: lower thirds i AR** — ten sam co cała klasa detektorów: FPR = 16,2% dla materiałów z animowanymi naklejkami broadcastowymi.
- **Ograniczenia generalizacji** — gorsza skuteczność dla modeli nieobjętych zbiorem treningowym.

5. Implementacja i ewaluacja systemu detekcji

Rozdział w przygotowaniu.

6. Wnioski i kierunki dalszych badań

Rozdział w przygotowaniu.

Bibliografia

[1] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville i Yoshua Bengio. „Generative Adversarial Nets”. W: *Advances in Neural Information Processing Systems (NeurIPS)*. 2014, s. 2672–2680.

[2] Carl Vondrick, Hamed Pirsiavash i Antonio Torralba. „Generating Videos with Scene Dynamics”. W: *Advances in Neural Information Processing Systems (NeurIPS)*. 2016, s. 613–621.

[3] Imran Khan, Khalil Khan i Asad Ahmad. „A Comprehensive Survey of DeepFake Generation and Detection Techniques in Audio-Visual Media”. W: *ICCK Journal of Image Analysis and Processing* 1.2 (2025), s. 73–95. DOI: *10.62762/JIAP.2025.431672*.

[4] Jonathan Ho, Ajay Jain i Pieter Abbeel. *Denoising Diffusion Probabilistic Models*. Preprint. 2020. arXiv: *2006.11239* [cs.LG].

[5] OpenAI. *Video Generation Models as World Simulators*. Technical Report. 2024.

[6] Runway. *Introducing Gen-3 Alpha: A New Frontier for Video Generation*. Blog post. 2024.

[7] Jian Li i in. „DeepFake Detection in the AIGC Era: A Survey”. W: *Information Fusion* (2025). DOI: *10.1016/j.inffus.2025.102802*.

[8] Yupeng Wang, Kwok-Yan Chow, Nan Yu i Jiaying Liu. „Deepfake Detection: A Comprehensive Survey from the Reliability Perspective”. W: *ACM Computing Surveys* (2024). DOI: *10.1145/3699710*.

[9] Falko Matern, Christian Riess i Marc Stamminger. „Exploiting Visual Artifacts to Expose Deepfakes and Face Manipulations”. W: *IEEE Winter Applications of Computer Vision Workshops (WACVW)*. 2019. DOI: *10.1109/WACVW.2019.00022*.

[10] Shicheng Dong i in. *Implicit Identity Leakage: The Stumbling Block to Improving Deepfake Detection Generalization*. Preprint. 2023. arXiv: *2310.10042* [cs.CV].

[11] Irene Amerini, Leonardo Galteri, Roberto Caldelli i Alberto Del Bimbo. „Deepfake Video Detection through Optical Flow Based CNN". W: *Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops (ICCVW)*. 2019, s. 1205–1207. DOI: *10.1109/ICCVW.2019.00152*.

[12] Roberto Caldelli, Leonardo Galteri, Irene Amerini i Alberto Del Bimbo. „Optical Flow based CNN for detection of unlearnt deepfake manipulations". W: *Pattern Recognition Letters* 146 (2021), s. 31–37. DOI: *10.1016/j.patrec.2021.03.005*.

[13] Ali Bou Nassif i in. „Improved Optical Flow Estimation Method for Deepfake Videos". W: *Sensors* 22.7 (2022), s. 2500. DOI: *10.3390/s22072500*.

[14] Joel Frank, Thorsten Eisenhofer, Lea Schönherr, Asja Fischer, Dorothea Kolossa i Thorsten Holz. „Leveraging Frequency Analysis for Deep Fake Image Recognition". W: *Proceedings of the International Conference on Machine Learning (ICML)*. 2020, s. 3247–3258.

[15] Joren Zhu, Russell Kaplan, Justin Johnson i Li Fei-Fei. „HiDDeN: Hiding Data With Deep Networks". W: *Proceedings of the European Conference on Computer Vision (ECCV)*. 2018, s. 657–672. DOI: *10.1007/978-3-030-01267-0_39*.

[16] Hao Luo, Lin Li i Jian Li. „Digital Watermarking Technology for AI-Generated Images: A Survey". W: *Mathematics* 13.4 (2025), s. 651. DOI: *10.3390/math13040651*.

[17] Amirhossein Najaf-Abadi i in. „An Automated and Robust Image Watermarking Scheme Based on Deep Neural Networks". W: *Expert Systems with Applications* (2024). DOI: *10.1016/j.eswa.2024.123752*.

[18] Xuandong Zhao i in. *Invisible Image Watermarks Are Provably Removable Using Generative AI*. Preprint. 2023. arXiv: *2306.01953* [cs.CV].

[19] Pierre Fernandez i in. *Blind Deep-Learning-Based Image Watermarking Robust Against Geometric Attacks*. Preprint. 2024. arXiv: *2402.09062* [cs.CV].

[20] Julien Piet i in. *SoK: Watermarking for AI-Generated Content*. Preprint. 2024. arXiv: *2411.18479* [cs.CR].

[21] Coalition for Content Provenance and Authenticity (C2PA). *C2PA Technical Specification v2.1*. Technical Specification. 2024.

[22] Andreas Rössler, Davide Cozzolino, Luisa Verdoliva, Christian Riess, Justus Thies i Matthias Nießner. „FaceForensics++: Learning to Detect Manipulated Facial Images". W: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2019, s. 1–11. DOI: *10.1109/ICCV.2019.00009*.

[23] Brian Dolhansky i in. *The DeepFake Detection Challenge (DFDC) Dataset*. Preprint. 2020. arXiv: *2006.07397* [cs.CV].

[24] Rui Shao, Tianxing Wu i Ziwei Liu. *Detecting and Grounding Multi-Modal Media Manipulation*. Preprint. 2023. arXiv: *2304.02556* [cs.CV].

[25] Zhiyuan Sun i in. *GenVideo: A Large-Scale Dataset and Benchmark for Detecting AI-Generated Video*. Preprint. 2024. arXiv: *2404.05219* [cs.CV].

[26] Zhen Peng i in. *Deepfake Generation and Detection*. Preprint. 2024. arXiv: *2403.17881* [cs.CV].